

Modelos de Média Móvel (MA) e Função de Autocorrelação (FAC/ACF)

Análise de séries temporais

Professora: Cristina Guedes

4 de outubro de 2026

Fundamentos Teóricos e Estacionariedade

Modelos de Média Móvel (MA)

Exemplos Práticos e Analíticos

Aplicações Práticas em Python

Conclusão

Fundamentos Teóricos e Estacionariedade

Conceito de Série Temporal e Processos Estocásticos

Uma série temporal $\{Z_t, t \in T\}$ é uma coleção de variáveis aleatórias ordenadas no tempo.

- **Realização:** O conjunto de dados observados $z_1, z_2, \dots, z_N$ representa apenas uma única trajetória (realização) do processo estocástico subjacente.
- **Ergodicidade:** Pressuposto que permite estimar momentos populacionais (como média e variância) a partir de uma única realização temporal.
- **Estrutura Temporal** Ao contrário de dados de corte transversal (*cross-section*), as observações subsequentes em séries temporais costumam ser fortemente dependentes entre si.

Definição (Ruído Branco / White Noise)

Um processo $\{\epsilon_t\}$ é chamado de Ruído Branco estrito/fraco se satisfaz:

1. $\mathbb{E}[\epsilon_t] = 0, \quad \forall t$
2. $\text{Var}(\epsilon_t) = \sigma_\epsilon^2 < \infty, \quad \forall t$
3. $\text{Cov}(\epsilon_t, \epsilon_s) = 0, \quad \forall t \neq s$

Denotamos por $\epsilon_t \sim N(0, \sigma_\epsilon^2)$.

Importância do Ruído Branco

Representa o choque aleatório não previsível (inovação pura). É o bloco fundamental para a construção de modelos mais complexos como MA, AR e ARIMA.

Definição (Estacionariedade Forte vs. Fraca)

- *****Estacionariedade Estrita:***** A distribuição conjunta de $(Z_{t_1}, \dots, Z_{t_k})$ é idêntica à de $(Z_{t_1+h}, \dots, Z_{t_k+h})$ para qualquer deslocamento h .
- *****Estacionariedade Fraca (Covariância-Estacionária):***** Exige apenas momentos de 1ª e 2ª ordens constantes no tempo:
 1. $\mathbb{E}[Z_t] = \mu$ (constante)
 2. $\text{Var}(Z_t) = \sigma^2 < \infty$ (constante)
 3. $\text{Cov}(Z_t, Z_{t-k}) = \gamma(k)$ (depende apenas do lag k)

Função de Autocovariância (FACv)

Definição (Autocovariância Teórica e Amostral)

A Função de Autocovariância no lag k mede a dependência linear entre Z_t e Z_{t-k} :

$$\gamma(k) = \text{Cov}(Z_t, Z_{t-k}) = \mathbb{E}[(Z_t - \mu)(Z_{t-k} - \mu)]$$

A sua estimadora amostral para uma série com N observações é:

$$\hat{\gamma}(k) = \frac{1}{N} \sum_{t=k+1}^N (Z_t - \bar{Z})(Z_{t-k} - \bar{Z})$$

Propriedades

- $\gamma(0) = \text{Var}(Z_t)$
- Simetria: $\gamma(k) = \gamma(-k)$

Função de Autocorrelação (FAC / ACF)

Definição (Função de Autocorrelação)

A Função de Autocorrelação (ACF) padroniza a autocovariância dividindo-a pela variância total da série:

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)} = \frac{\text{Cov}(Z_t, Z_{t-k})}{\text{Var}(Z_t)}$$

A estimadora amostral é dada por $\hat{\rho}(k) = \frac{\hat{\gamma}(k)}{\hat{\gamma}(0)}$.

Propriedades Fundamentais da FAC

- $\rho(0) = 1$
- Simetria em relação à origem: $\rho(k) = \rho(-k)$
- Limites normalizados: $-1 \leq \rho(k) \leq 1$

Teorema da Decomposição de Wold

Teorema (Decomposição de Wold)

Qualquer processo estocástico covariância-estacionário $\{Z_t\}$ pode ser representado como a soma de dois processos não correlacionados:

$$Z_t = \mu + \sum_{j=0}^{\infty} \psi_j \epsilon_{t-j} + V_t$$

Onde:

- $\epsilon_t \sim N(0, \sigma_\epsilon^2)$ é o processo de inovação.
- $\psi_0 = 1$ e $\sum_{j=0}^{\infty} \psi_j^2 < \infty$.
- V_t é um processo puramente determinístico.

Implicação

Todo processo estacionário pode ser aproximado por uma combinação linear de ruídos brancos passados (processo MA de ordem finita ou infinita).

Modelos de Média Móvel (MA)

O Modelo $MA(q)$

Definição (Processo Média Móvel de Ordem q)

O processo $MA(q)$ expressa a observação atual como uma combinação linear ponderada da inovação atual e de q inovações passados:

$$Z_t = \mu + \epsilon_t - \theta_1\epsilon_{t-1} - \theta_2\epsilon_{t-2} - \cdots - \theta_q\epsilon_{t-q}$$

, onde $\epsilon_t \sim N(0, \sigma_\epsilon^2)$ e $\theta_1, \dots, \theta_q$ são os parâmetros do modelo.

Teorema (Estacionariedade Incondicional)

*Qualquer processo $MA(q)$ de ordem finita é **sempre estacionário**, independentemente dos valores dos coeficientes θ_i , pois é uma soma finita de componentes estacionários.*

Operador de Defasagem e Polinômio MA

Utilizando o operador de defasagem B ($B^k Z_t = Z_{t-k}$), podemos reescrever o modelo MA(q) de forma compacta.

$$Z_t = \mu + (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q) \epsilon_t$$

Definindo o polinômio do operador média móvel $\theta(B)$:

$$\theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q$$

Assim, o processo assume a forma matricial/operacional:

$$(Z_t - \mu) = \theta(B) \epsilon_t$$

Invertibilidade do Modelo MA

Apesar de sempre estacionário, exigimos a propriedade de ****invertibilidade**** para que o erro presente ϵ_t possa ser expresso em função do histórico de observações $Z_t, Z_{t-1}, Z_{t-2}, \dots$.

$$(Z_t - \mu) = \theta(B)\epsilon_t \implies \theta(B)^{-1}(Z_t - \mu) = \epsilon_t$$

Teorema (Condição do Círculo Unitário)

*O processo $MA(q)$ é invertível se, e somente se, todas as raízes da equação característica $\theta(z) = 0$ estiverem estritamente ****fora do círculo unitário**** no plano complexo:*

$$|z| > 1, \quad \forall z \in \mathbb{C} \text{ tal que } \theta(z) = 0$$

Exemplos Práticos e Analíticos

Exemplo Prático Inicial: Estimando a Esperança de um MA(1)

Suponha que observamos uma amostra de retornos diários Z_t gerada por um processo MA(1) com constante μ :

$$Z_t = \mu + \epsilon_t - \theta_1 \epsilon_{t-1}, \quad \text{onde } \mathbb{E}[\epsilon_t] = 0$$

Dados Observados ($N = 5$ dias):

Dia (t)	1	2	3	4	5
z_t (%)	2,5	1,0	3,5	0,5	2,5

Cálculo da Esperança Amostral ($\hat{\mu} = \mathbb{E}[Z_t]$):

$$\hat{\mu} = \bar{Z} = \frac{1}{N} \sum_{t=1}^N z_t = \frac{2,5 + 1,0 + 3,5 + 0,5 + 2,5}{5} = \frac{10,0}{5} = 2,0\%$$

Interpretação

Como $\mathbb{E}[Z_t] = \mathbb{E}[\mu + \epsilon_t - \theta_1 \epsilon_{t-1}] = \mu + 0 - 0 = \mu$, a média amostral $\bar{Z} = 2,0\%$ é um estimador não viesado para a esperança teórica $\mathbb{E}[Z_t]$.

Exemplo Teórico 1: Análise Completa do MA(1)

Considere o processo MA(1) com média zero:

$$Z_t = \epsilon_t - \theta_1 \epsilon_{t-1}, \quad \epsilon_t \sim N(0, \sigma_\epsilon^2)$$

1. Média:

$$\mathbb{E}[Z_t] = \mathbb{E}[\epsilon_t] - \theta_1 \mathbb{E}[\epsilon_{t-1}] = 0$$

2. Variância ($\gamma(0)$):

$$\gamma(0) = \mathbb{E}[(\epsilon_t - \theta_1 \epsilon_{t-1})^2] = \mathbb{E}[\epsilon_t^2] - 2\theta_1 \mathbb{E}[\epsilon_t \epsilon_{t-1}] + \theta_1^2 \mathbb{E}[\epsilon_{t-1}^2] = \sigma_\epsilon^2(1 + \theta_1^2)$$

3. Autocovariância no Lag 1 ($\gamma(1)$):

$$\gamma(1) = \mathbb{E}[(\epsilon_t - \theta_1 \epsilon_{t-1})(\epsilon_{t-1} - \theta_1 \epsilon_{t-2})] = -\theta_1 \mathbb{E}[\epsilon_{t-1}^2] = -\theta_1 \sigma_\epsilon^2$$

Exemplo Teórico 1: FAC e Invertibilidade do MA(1)

Para defasagens $k \geq 2$, $\gamma(k) = 0$. Assim, a FAC Teórica do MA(1) é:

$$\rho(k) = \begin{cases} 1, & \text{se } k = 0 \\ \frac{-\theta_1}{1+\theta_1^2}, & \text{se } k = 1 \\ 0, & \text{se } k \geq 2 \end{cases}$$

Invertibilidade do MA(1)

A equação característica é $\theta(z) = 1 - \theta_1 z = 0 \implies z = \frac{1}{\theta_1}$.

Para invertibilidade: $|z| > 1 \implies \left| \frac{1}{\theta_1} \right| > 1 \implies |\theta_1| < 1$.

Exemplo Teórico 2: Derivação das Equações do MA(2)

Considere o processo MA(2) com $\mathbb{E}[Z_t] = 0$:

$$Z_t = \epsilon_t - \theta_1\epsilon_{t-1} - \theta_2\epsilon_{t-2}, \quad \epsilon_t \sim N(0, \sigma_\epsilon^2)$$

1. Variância: $\gamma(0) = \text{Var}(Z_t) = \sigma_\epsilon^2(1 + \theta_1^2 + \theta_2^2)$

2. Autocovariâncias ($\gamma(1)$ e $\gamma(2)$):

$$\begin{aligned}\gamma(1) &= \mathbb{E}[(\epsilon_t - \theta_1\epsilon_{t-1} - \theta_2\epsilon_{t-2})(\epsilon_{t-1} - \theta_1\epsilon_{t-2} - \theta_2\epsilon_{t-3})] \\ &= -\theta_1\sigma_\epsilon^2 + \theta_1\theta_2\sigma_\epsilon^2 = -\theta_1(1 - \theta_2)\sigma_\epsilon^2\end{aligned}$$

$$\gamma(2) = \mathbb{E}[(\epsilon_t - \theta_1\epsilon_{t-1} - \theta_2\epsilon_{t-2})(\epsilon_{t-2} - \theta_1\epsilon_{t-3} - \theta_2\epsilon_{t-4})] = -\theta_2\sigma_\epsilon^2$$

Para $k \geq 3$, temos $\gamma(k) = 0$.

Exemplo Teórico 2: FAC e Triângulo de Invertibilidade do MA(2)

A FAC Teórica do modelo MA(2) é:

$$\rho(1) = \frac{-\theta_1(1 - \theta_2)}{1 + \theta_1^2 + \theta_2^2}, \quad \rho(2) = \frac{-\theta_2}{1 + \theta_1^2 + \theta_2^2}, \quad \rho(k) = 0 \quad (\forall k \geq 3)$$

Condições de Invertibilidade do MA(2)

As raízes de $1 - \theta_1 z - \theta_2 z^2 = 0$ devem estar fora do círculo unitário. Isso impõe 3 restrições simultâneas aos parâmetros (Triângulo de Invertibilidade):

$$\begin{cases} \theta_2 + \theta_1 < 1 \\ \theta_2 - \theta_1 < 1 \\ -1 < \theta_2 < 1 \end{cases}$$

Exemplo Teórico 3: Cálculo da FAC Generalizada para MA(q)

Para um processo MA(q) genérico com $Z_t = \mu + \epsilon_t - \sum_{j=1}^q \theta_j \epsilon_{t-j}$:

1. Variância Teórica:

$$\gamma(0) = \sigma_{\epsilon}^2 \left(1 + \sum_{j=1}^q \theta_j^2 \right)$$

2. Autocovariância no Lag k ($1 \leq k \leq q$):

$$\gamma(k) = \sigma_{\epsilon}^2 \left(-\theta_k + \sum_{j=1}^{q-k} \theta_j \theta_{j+k} \right)$$

3. Corte Bruto: $\gamma(k) = 0$ e $\rho(k) = 0$ para todo $k > q$.

Exemplo Teórico 4: Teste Estatístico e Bandas de Bartlett

Para identificar se os coeficientes amostrais $\hat{\rho}(k)$ são estatisticamente significativos, utilizamos os resultados assintóticos de Bartlett.

Teorema (Erro Padrão da FAC sob a Hipótese Nula de Ruído Branco)

Se $\{Z_t\}$ for um Ruído Branco de tamanho N , a distribuição amostral de $\hat{\rho}(k)$ para $k > 0$ é assintoticamente normal:

$$\hat{\rho}(k) \sim \mathcal{N}\left(0, \frac{1}{N}\right)$$

Intervalo de Confiança de 95%

O limite de significância estatística é dado por:

$$IC_{95\%} = \left[-\frac{1.96}{\sqrt{N}}, \frac{1.96}{\sqrt{N}} \right]$$

Se $|\hat{\rho}(k)| > \frac{1.96}{\sqrt{N}}$, rejeita-se a hipótese nula de ausência de autocorrelação no lag k .

Aplicações Práticas em Python

Exemplo 1 (Python): Suavização por Média Móvel Simples

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4
5 # Criando dados sinteticos de vendas
6 np.random.seed(42)
7 datas = pd.date_range(start='2026-01-01', periods=100, freq='D')
8 ruido = np.random.normal(0, 5, 100)
9 tendencia = np.linspace(10, 50, 100)
10 vendas = tendencia + ruido
11
12 df = pd.DataFrame({'Data': datas, 'Vendas': vendas}).set_index('Data')
13
14 # 1. Media Movel Simples (SMA) de 7 e 14 dias
15 df['SMA_7'] = df['Vendas'].rolling(window=7).mean()
16 df['SMA_14'] = df['Vendas'].rolling(window=14).mean()
17
18 print(df.tail(5))
```

Exemplo 2 (Python): Simulação de Modelo Estocástico MA(2)

```
1 from statsmodels.tsa.arima_process import ArmaProcess
2 import matplotlib.pyplot as plt
3
4 # Definindo um processo MA(2):  $Z_t = e_t + 0.6e_{t-1} - 0.3e_{t-2}$ 
5 # Nota: Em statsmodels, os sinais do polinomio MA usam convencao oposta
6 ar_params = np.array([1])          # Sem componente AR
7 ma_params = np.array([1, 0.6, -0.3]) # Coeficientes do MA(2)
8
9 processo_ma2 = ArmaProcess(ar_params, ma_params)
10
11 # Simulando 500 observacoes
12 np.random.seed(123)
13 dados_ma2 = processo_ma2.generate_sample(nsample=500)
14
15 plt.figure(figsize=(8, 3))
16 plt.plot(dados_ma2, color='navy', linewidth=1)
17 plt.title('Serie Temporal Simulada de um Processo MA(2)')
18 plt.savefig('ma2_simulation.png')
```


Exemplo 3 (Python): FAC Amostral e Gráfico Correlogram

```
1 import statsmodels.api as sm
2 from statsmodels.graphics.tsaplots import plot_acf
3 import matplotlib.pyplot as plt
4
5 # Gerando serie estocastica
6 np.random.seed(42)
7 serie = np.random.randn(200)
8
9 # 1. Calculo explicito da FAC amostral ate o lag 10
10 fac_valores = sm.tsa.stattools.acf(serie, nlags=10)
11 print("Valores da FAC (lags 0 a 10):")
12 print(np.round(fac_valores, 3))
13
14 # 2. Plotagem do Correlograma com Intervalo de Confianca
15 fig, ax = plt.subplots(figsize=(8, 3))
16 plot_acf(serie, lags=20, ax=ax, alpha=0.05)
17 plt.title("Correlograma (FAC Amostral)")
18 plt.savefig('acf_plot.png')
```

Exemplo 4 (Python): Diagnóstico de FAC em Processo MA(1)

```
1 # Verificando a propriedade de corte da FAC em um MA(1)
2 #  $Z_t = e_t - 0.8 * e_{t-1}$  ( $\theta_1 = 0.8$ )
3 ar_ma1 = np.array([1])
4 ma_ma1 = np.array([1, -0.8])
5
6 processo_ma1 = ArmaProcess(ar_ma1, ma_ma1)
7 dados_ma1 = processo_ma1.generate_sample(nsample=1000)
8
9 # Plot da FAC - Espera-se significancia apenas no lag 1
10 fig, ax = plt.subplots(figsize=(8, 3))
11 plot_acf(dados_ma1, lags=10, ax=ax, title="FAC do MA(1): Identificacao do Corte no Lag 1")
12 plt.show()
```

Exemplo 5 (Python): Comparativo FAC Teórica vs. Amostral

```
1 # Comparacao entre a FAC teorica calculada e a FAC amostral estimada
2 theta1 = 0.7
3 ma_params = np.array([1, -theta1])
4 processo = ArmaProcess(np.array([1]), ma_params)
5
6 # FAC Teorica exata
7 fac_teorica = processo.acf(lags=5)
8
9 # Amostra com N=500
10 np.random.seed(42)
11 amostra = processo.generate_sample(nsample=500)
12 fac_amostrai = sm.tsa.stattools.acf(amostra, nlags=5)
13
14 df_comparacao = pd.DataFrame({
15     'Lag': range(6),
16     'FAC Teorica': fac_teorica,
17     'FAC Amostral (N=500)': fac_amostrai
18 })
19 print(df_comparacao.round(4))
```

Exemplo 6 (Python): Teste de Ruído Branco via Ljung-Box

```
1 from statsmodels.stats.diagnostic import acorr_ljungbox
2
3 # Teste formal de hipótese para autocorrelação global (Ljung-Box)
4 # H0: A série é um ruído branco (sem autocorrelação até o lag k)
5 np.random.seed(42)
6 dados_ruído = np.random.normal(0, 1, 300)
7
8 # Executando o teste até o lag 10
9 resultado_lb = acorr_ljungbox(dados_ruído, lags=[5, 10], return_df=True)
10 print(resultado_lb)
11
12 # Se p-value > 0.05, não rejeitamos H0 (confirma Ruído Branco)
```

Conclusão

Resumo dos Conceitos e Matriz Comparativa

Modelo	Comportamento da FAC ($\rho(k)$)	Condições Principais
Ruído Branco	$\rho(k) = 0, \quad \forall k \geq 1$	Média zero e variância constante
MA(1)	Pico no lag 1; zero para $k \geq 2$	Invertível se $ \theta_1 < 1$
MA(2)	Picos nos lags 1 e 2; zero para $k \geq 3$	Triângulo de Invertibilidade
MA(q)	Trunca (corta a zero) após lag q	Raízes de $\theta(z) = 0$ fora de $ z = 1$

Metodologia Box-Jenkins

O comportamento da **FAC** é o principal identificador visual para a ordem q dos modelos de média móvel $MA(q)$, caracterizado pelo **corte abrupto** após a defasagem q .

- **Próximo Tópico:** Modelos Autorregressivos $AR(p)$ e a Função de Autocorrelação Parcial (FACP / PACF).
- **Leitura Recomendada:** Box, G. E., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: forecasting and control*. John Wiley & Sons.